맛집 데이터와 공공데이터를 이용한 서울시 자치구별 맛집 상권분석

데이터시각화 프로젝트

2조

김승규
정현진
김경민
정서연
이선희

구성원 및 역할

팀장 김승규

1. 구의 인구수와 맛집 수 관계
2. 구별 맛집 가격대 점수
   2-1. 구별 메뉴 가격대 점수
3. 구의 소득세와 맛집 가격 관계
   3-1. 구의 소득세와 메뉴가격 관계

팀원 김경민

1. 인구수와 리뷰수의 상관관계
2. 구 별 GDP와 맛집의 평균가격 상관관계
3. 구 별 GDP와 가격점수의 상관관계

팀원 정현진

1. 구 별 맛집 수
2. 음식 종류 별 맛집 수
3. 가격대 별 맛집 수
4. 서울 지도에 맛집의 좌표 값을 이용해 마커를 찍고
   마커 안에 간단한 정보를 삽입
5. 구 별 맛집 수 단계구분도 표현
6. 구별 맛집 수와 사업체 종사자수 간의 상관 관계
7. 구별 맛집 수와 사업체 수 간의 상관 관계
8. 인접역에서의 거리에 따른 맛집 수
9. 인접대학교에서의 거리에 따른 맛집 수
10. 구의 소득세와 맛집 가격 관계 단계구분도
11. 구의 소득세와 메뉴가격 관계 단계구분도

팀원 정서연

1. 구별 소득세와 맛집 평균가격의 관계
2. 구별 GDP와 맛집 가격점수의 관계

팀원 이선희

가격대별 맛집 만족도 비교
1)가격대별 맛 평가(맛있다,괜찮다, 별로다) 비율
2)가격대별 맛집의 평균 평점 비교

CONTENTS

01 프로젝트 개요

01 프로젝트 개요

1-1 프로젝트 기획 배경

[단위: 곳]

출처: 행정안전부 / 분석 및 제공: 상가정보연구소

01 프로젝트 개요

1-2 프로젝트 목표

01 서울시 다양한 공공데이터 활용 및 크롤링을 통한 맛집데이터 수집

02 맛집 데이터와 공공데이터 간의 다양한 상관관계 분석

03 서울시 맛집 상권분석에 필요한 다양한 인사이트 도출 및 창업 아이디어 제안

02 데이터 프로세싱

02 데이터 프로세싱

2-1 데이터 수집

서울 열린데이터 광장
SEOUL OPEN DATA PLAZA

https://data.seoul.go.kr/

공공데이터 수집 List

1. 서울시 자치구 별 인구수
2. 서울시 자치구 별 소득세
3. 서울시 자치구 별 GDP
4. 서울시 자치구 별 사업체 수
5. 서울시 자치구 별 사업체 종사자 수
6. 서울시 소재 지하철역 주소
7. 서울시 소재 대학교 주소

02 데이터 프로세싱

2-2 웹 크롤링

1. 망고 플레이트 서비스에서 서울시 구별로 필요한 데이터의 목록을 빈리스트로 생성

데이터 수집 사이트

https://www.mangoplate.com/

크롤링에 사용한 프레임워크

Selenium

02 데이터 프로세싱

2-2 웹 크롤링

2. 서울시 25개 구 리스트 생성


```
#서울시 구 리스트
gu_list=['도봉구','노원구','강북구','은평구','종로구','성북구','동대문구','중랑구','서대문구',\
         '마포구','중구','용산구','성동구','광진구','강동구','송파구','강남구',\
         '강서구','양천구','영등포구','동작구','서초구','관악구','금천구','구로구']
```

02 데이터 프로세싱

2-2 웹 크롤링

3. 크롤링 진행

```
xpath = '//*[@id="main-search"]'
g = driver.find_element(By.XPATH, xpath)

for u in gu_list:
    base_url = "https://www.mangoplate.com/search/"+u+"?keyword="+u+"&page="
    for n in range(1,2):
        urls = base_url + str(n)
        driver.get(urls)
        time.sleep(7)
        for i in range(1,11):
            for j in range(1,3):
                xpath='/html/body/main/article/div[2]/div/div/section/div[3]/ul/li[{0}]/div[{1}]/figure/figcaption/div/a'.format(i,j)
                time.sleep(7)
                q=driver.find_element(By.XPATH, xpath)
                driver.execute_script("arguments[0].click();",q)
                time.sleep(7)

                #식당명

                try:
                    restaurant_name.append(driver.find_element(By.XPATH,'//h1').text)
                except:
                    restaurant_name.append(' ')
```

02 데이터 프로세싱

2-2 웹 크롤링

3. 데이터 정제

■불필요한 반복문자 삭제처리

```
df1['주소']=df1['주소'].str.replace('주소','')
df1['구']=df1['구'].str.replace('서울시','')
df1['음식종류']=df1['음식종류'].str.replace('음식 종류','')
df1['가격대']=df1['가격대'].str.replace('가격대','')
```

■데이터 병합 후 인덱스 재설정

```
df=pd.concat([df1,df2,df3,df4,df5])
```

```
df.reset_index(drop=True,inplace=True)
```

■데이터 밀리는 부분 수정 전처리

```
wrong = df['음식종류'].str.contains("가격대")
wrong_df = df[wrong]
index = wrong_df.index.to_list()
```

```
for i in index:
    a = df.loc[i, '음식종류']

    df.loc[i, '가격대'] = a
    df.loc[i, '음식종류'] = 0
```

02 데이터 프로세싱

2-2 웹 크롤링

4. 데이터프레임 생성

	식당명	별점	구	주소	음식종류	가격대	리뷰날짜	리뷰평가	리뷰수	맛있다수	괜찮다수	별로다수
0	이코이	4.4	도봉구	서울특별시 도봉구 도봉로112길 20	돈부리 / 일본 카레 / 벤토	만원-2만원	2022-05-29	맛있다	37	32.0	4.0	1.0
1	패멩베이커리	4.3	도봉구	서울특별시 도봉구 도봉로116길 4	카페 / 디저트	만원 미만	2022-04-18	맛있다	7	7.0	0.0	0.0
2	스마일닭강정	4.3	도봉구	서울특별시 도봉구 도봉로110아길 7 1F	닭 / 오리 요리	만원 미만	2022-03-19	맛있다	7	7.0	0.0	0.0
3	코노하카레	4.2	도봉구	서울특별시 도봉구 우이천로20길 7 103동상가 1F	돈부리 / 일본 카레 / 벤토	만원-2만원	2022-02-07	맛있다	38	32.0	6.0	0.0
4	버거브라더	4.2	도봉구	서울특별시 도봉구 마들로 657 1F	브런치 / 버거 / 샌드위치	만원 미만	2022-06-30	맛있다	8	7.0	1.0	0.0

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5000 entries, 0 to 4999
Data columns (total 12 columns):
 #   Column   Non-Null Count  Dtype
---  ------   --------------  -----
 0   식당명      5000 non-null   object
 1   별점       3417 non-null   float64
 2   구         5000 non-null   object
 3   주소        5000 non-null   object
 4   음식종류     5000 non-null   object
 5   가격대      5000 non-null   object
 6   리뷰날짜     5000 non-null   object
 7   리뷰평가     5000 non-null   object
 8   리뷰수      5000 non-null   int64
 9   맛있다수     4931 non-null   float64
 10  괜찮다수     4931 non-null   float64
 11  별로다수     4931 non-null   float64
dtypes: float64(4), int64(1), object(7)
```

열 개수: 12개
행 개수: 5000개

03 데이터 시각화

03 데이터 시각화

#1

기본 시각화

#2

인구

#3

활동인구/
사업체/인프라

#4

소득(GDP)

03 데이터 시각화

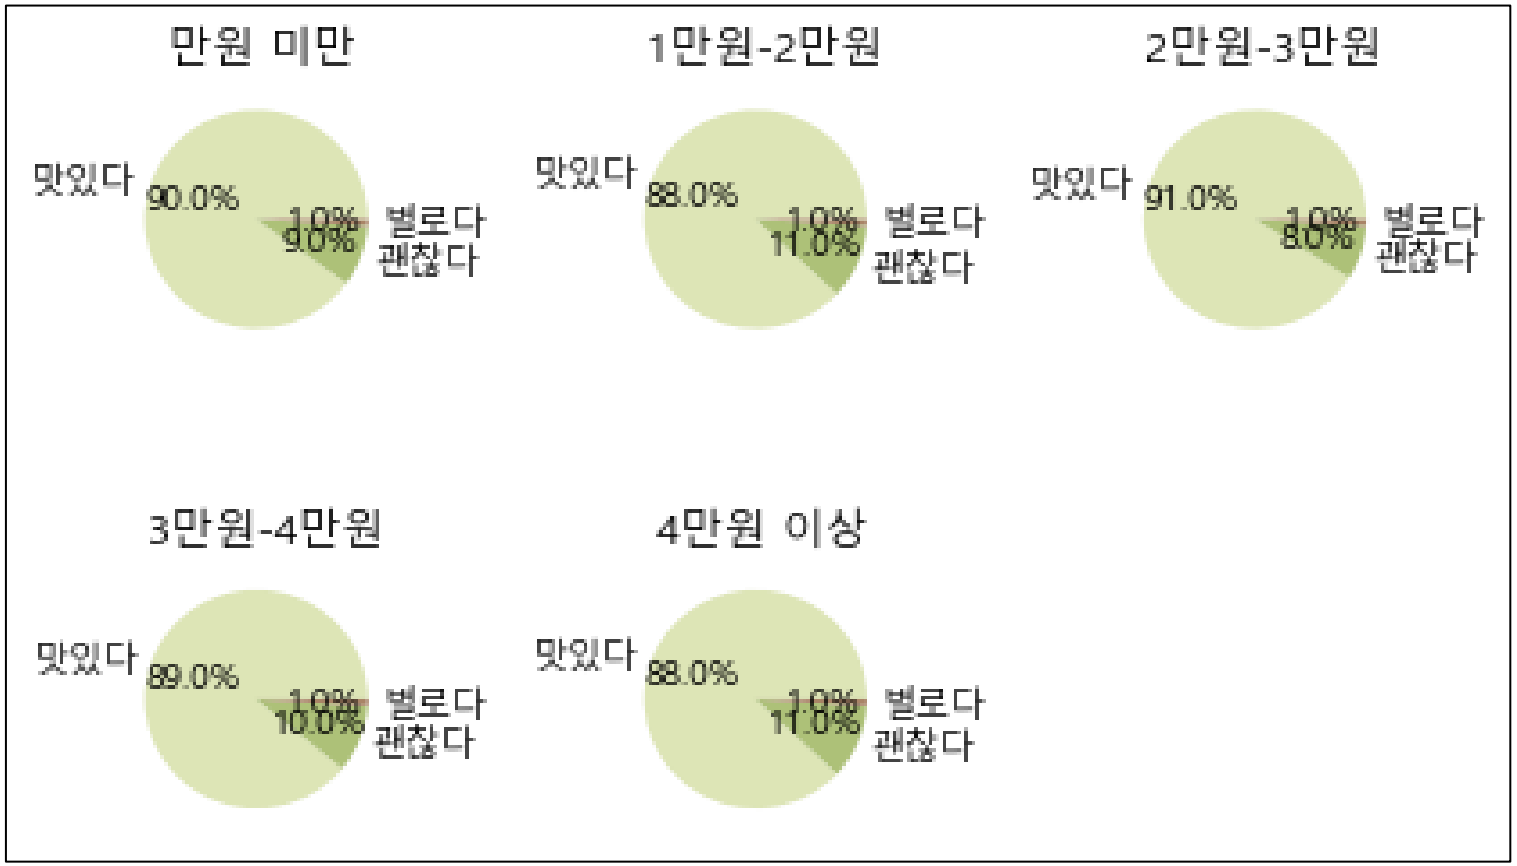

< 가격대별 맛 평가 (맛있다,괜찮다,별로다) 비율>

■가중치를 적용하여 새로운 평점 산출

(별점*맛있다 수 - 2*별점*별로다 수)/전체 리뷰수

03 데이터 시각화

	식당명	별점	구	주소	음식종류	가격대	리뷰날짜	리뷰평가	리뷰수	맛있다수	괜찮다수	별로다수	최종평점
0	도이칠란드 박	4.6	성북구	서울특별시 성북구 솔샘로6길 30-15 1F	다국적음식	만원-2만원	2022-07-04	맛있다	21.0	19.0	0.0	2.0	3.285714
1	뽀르께노 스페니쉬비스트로	4.6	성북구	서울특별시 성북구 동소문로6길 4-21 1F	다국적음식	만원-2만원	2022-07-22	맛있다	7.0	7.0	0.0	0.0	4.600000
2	공푸	4.5	성북구	서울특별시 성북구 삼선교로24길 29	중식	만원 미만	2022-07-07	별로	91.0	76.0	11.0	4.0	3.362637
3	성북동집	4.5	성북구	서울특별시 성북구 성북로24길 4	한식	만원-2만원	2022-07-28	맛있다	41.0	35.0	6.0	0.0	3.841463
4	계모임	4.5	성북구	서울특별시 성북구 보문로30라길 5-10 1F	한식	만원-2만원	5 일 전	맛있다	10.0	10.0	0.0	0.0	4.500000

03 데이터 시각화

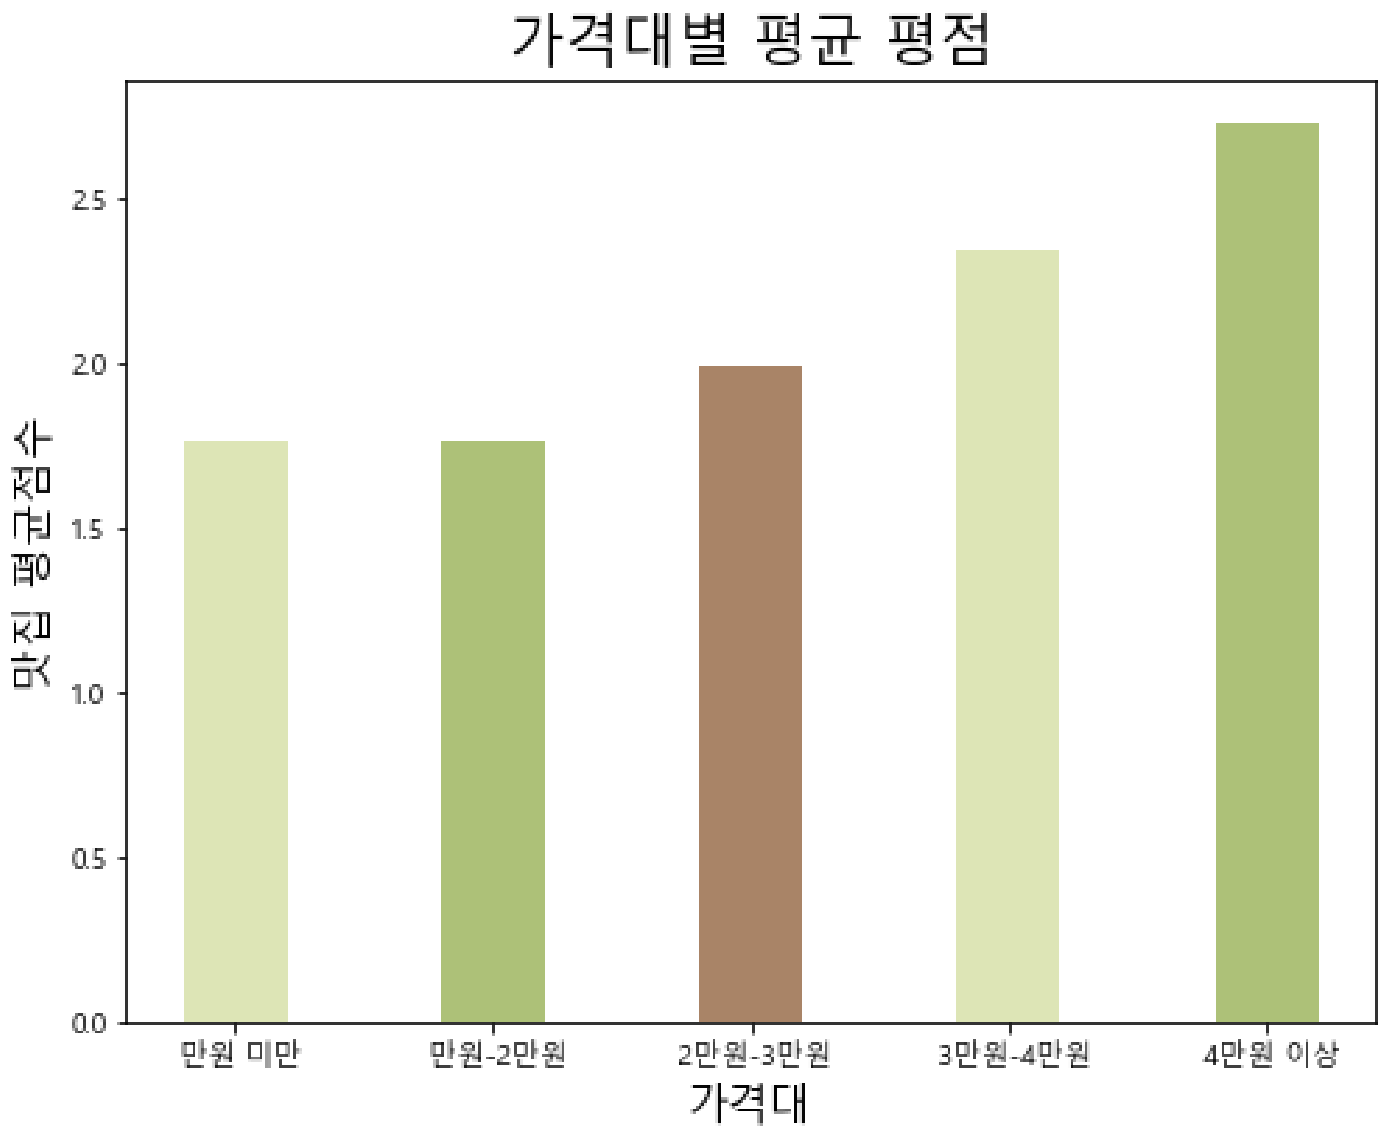

가격대 ↑ → 맛집 평균점수 ↑

03 데이터 시각화

■가격점수 도출 이유

기존에 수집한 가격대별 맛집수의 절대적인 데이터에 가중치를 주어 상대적인 값(가격점수)로 변환한 뒤 데이터 분석에 활용

구	10000원 미만	20000원 미만	30000원 미만	40000원 미만	40000원 이상	맛집수	가격 점수
강남구	30	59	34	22	55	200	3.065000
강동구	88	69	19	5	2	183	1.710383
강북구	95	67	14	3	1	180	1.600000
강서구	82	78	21	3	10	194	1.871134
관악구	91	79	18	1	2	191	1.659686
광진구	102	76	12	4	4	198	1.646465
구로구	68	90	27	3	1	189	1.830688
금천구	87	71	11	2	4	175	1.657143

■가격점수 계산식

```
Fin_df['가격 점수'] = (Fin_df['10000원 미만'] + 2*Fin_df['20000원 미만'] \
                    + 3*Fin_df['30000원 미만'] + 4*Fin_df['40000원 미만'] + 5*Fin_df['40000원 이상']) / Fin_df['맛집수']
```

03 데이터 시각화

<구 별 맛집 가격대 비교>

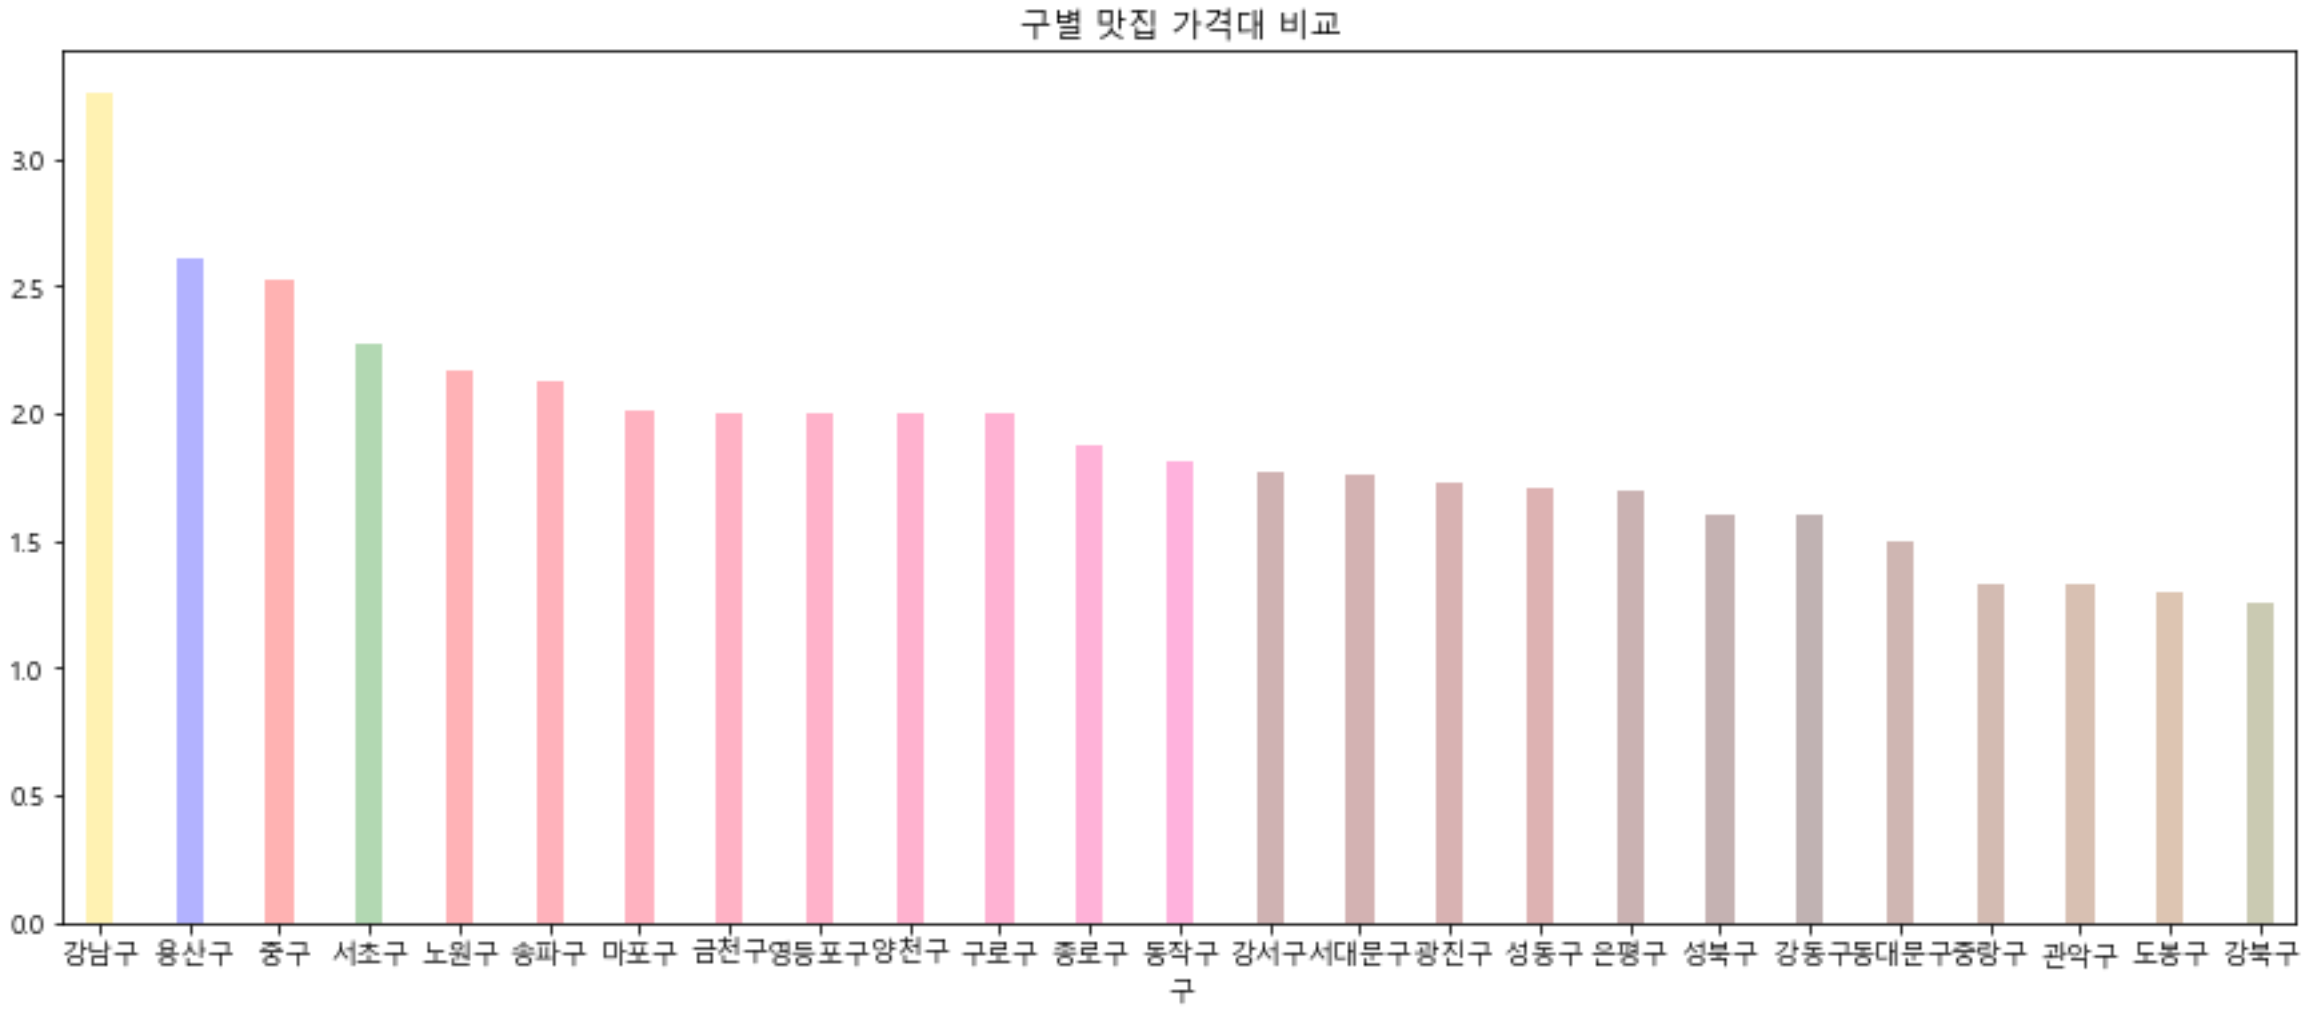

03 데이터 시각화

#1

기본 시각화

#1 기본시각화

<서울시 구별 맛집 개수 분포>

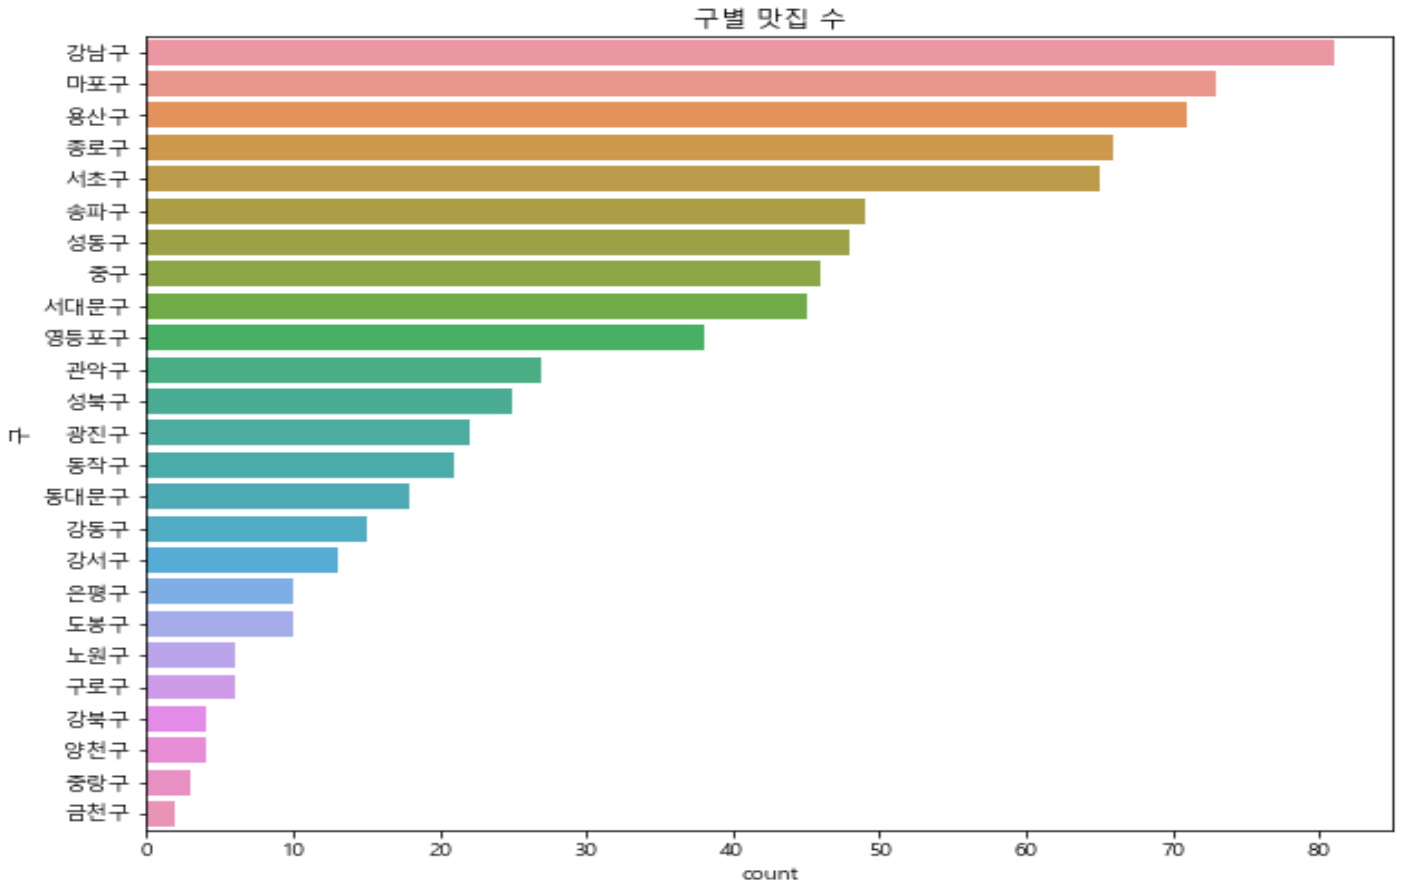

#1 기본시각화

<음식 종류에 따른 서울시 구별 맛집 개수>

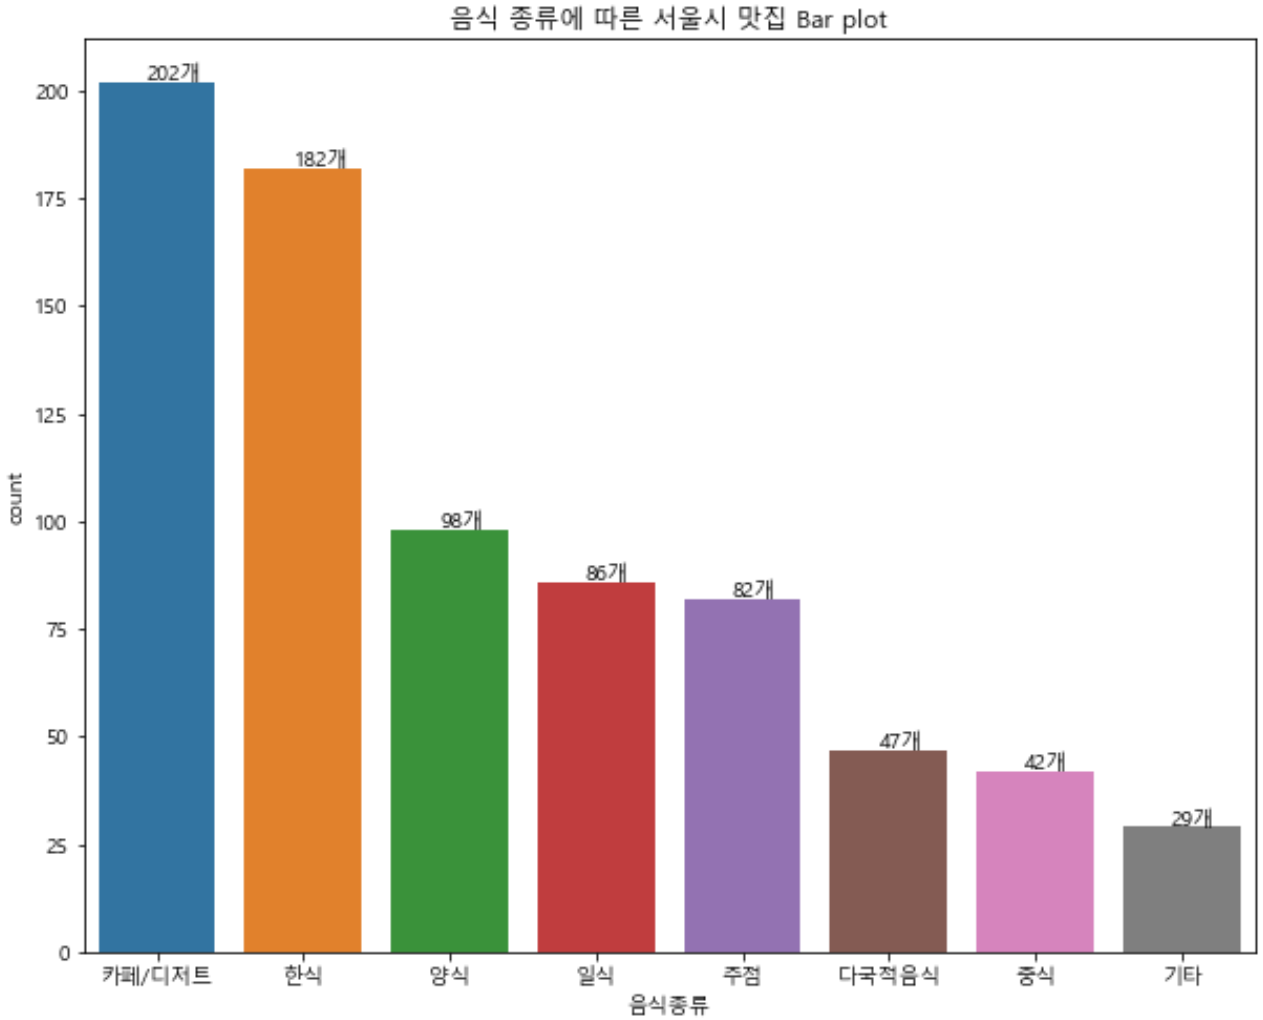

#1 기본시각화

<음식 가격대별 서울시 맛집 개수>

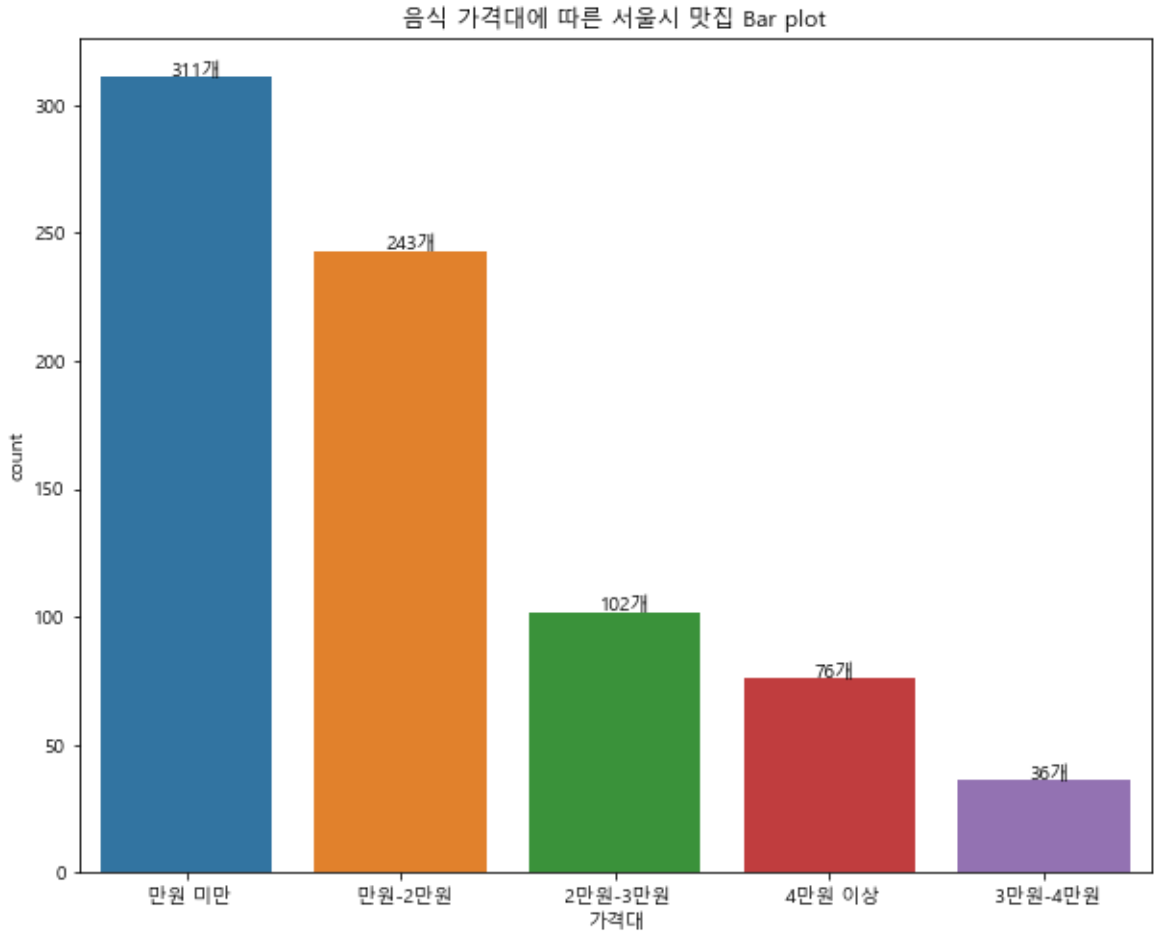

#1 기본시각화

<지도에 맛집정보,위치 마커 표시>

■주소를 위경도 값으로 반환하는 함수

```
def geocoding(address):
    try:
        geo = geo_local.geocode(address)
        x_y = [geo.latitude, geo.longitude]
        return x_y

    except:
        return [0,0]
```

■folium.Map활용해 지도에 맛집 표현

```
map = folium.Map(location=[37.5502, 126.982], zoom_start=11)

for n in df.index:
    folium.Marker(
        [latitude[n],longitude[n]],
        radius = 10,
        color='#3186cc',
        fill_color='#3186cc',
        fill=True,
        tooltip  = ('<b>- 지역</b>: ' + df['구'][n] + '<br>' +
                '<b>- 상호명</b>: ' + df['식당명'][n] + '<br>' +
                   '<b>- 평점</b>: ' + str(round(df['평점'][n], 2)) + '<br>' +
                '<b>- 음식분류</b>: ' + df['음식종류'][n] + '<br>' +
                  '<b>- 가격대</b>: ' + df['가격대'][n])
    ).add_to(map)
map
```

#1 기본시각화

<서울시 구별 맛집 수 단계구분도>

■단계구분도 표현 코드

```
geo_path='./data/02. skorea_municipalities_geo_simple.json'
geo_str = json.load(open(geo_path, encoding = 'utf-8'))
# geo_str

#서울을 중심으로 기본 지도 출력
#위경도[37.5502,126.982]
map=folium.Map(location=[37.5502,126.982],
               zoom_start=11,)
               #tiles='Stamen Terrain')
f_test=view
map.choropleth(geo_data=geo_str,
               data=f_test,
               columns=[f_test.index,'가격 점수'],
               key_on = 'feature.id',
               fill_color='BuPu',
               legend_name='구 별 가격점수')
folium.LayerControl().add_to(map)
map
```

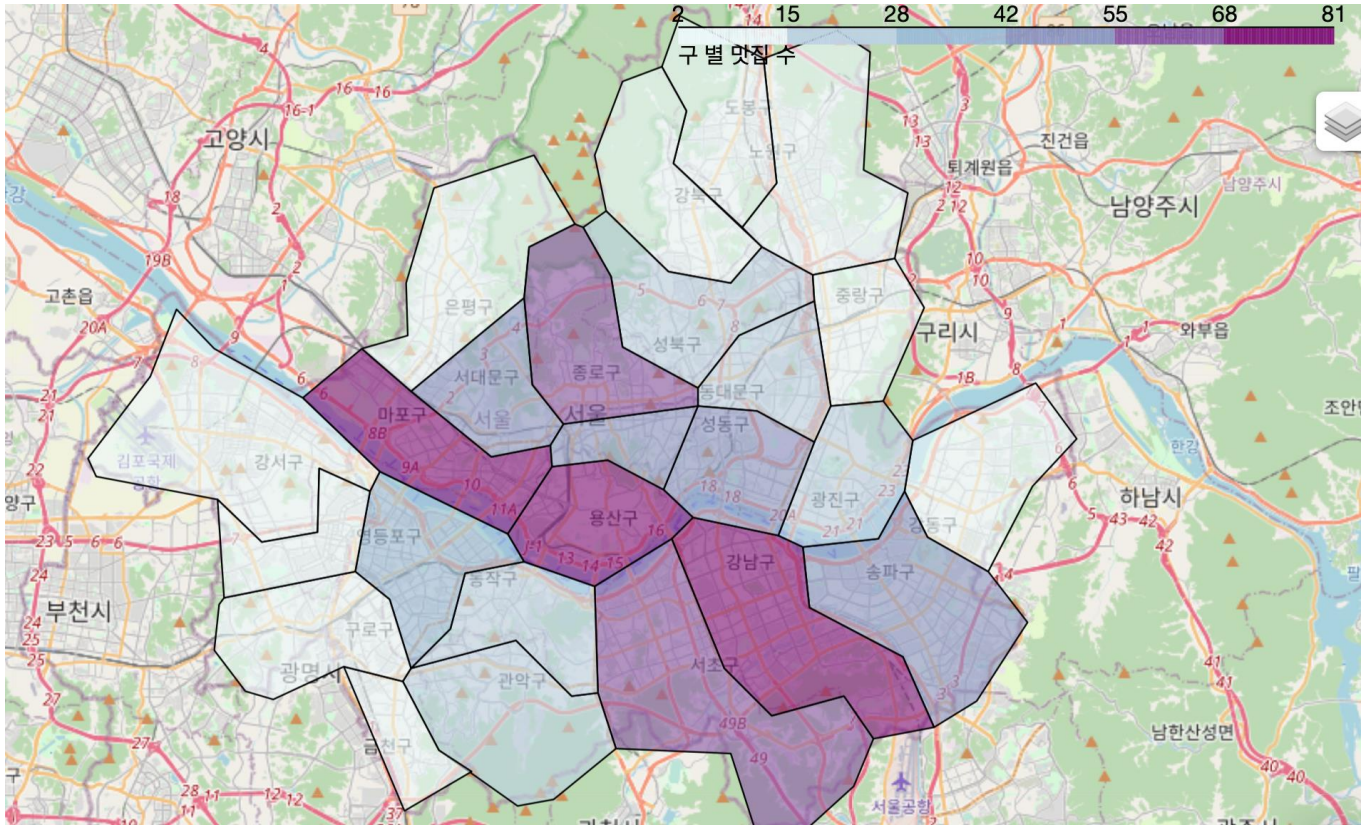

03 데이터 시각화

#2

인구

#2 인구

< 구 별 맛집 수와 인구 수 간의 상관관계 >

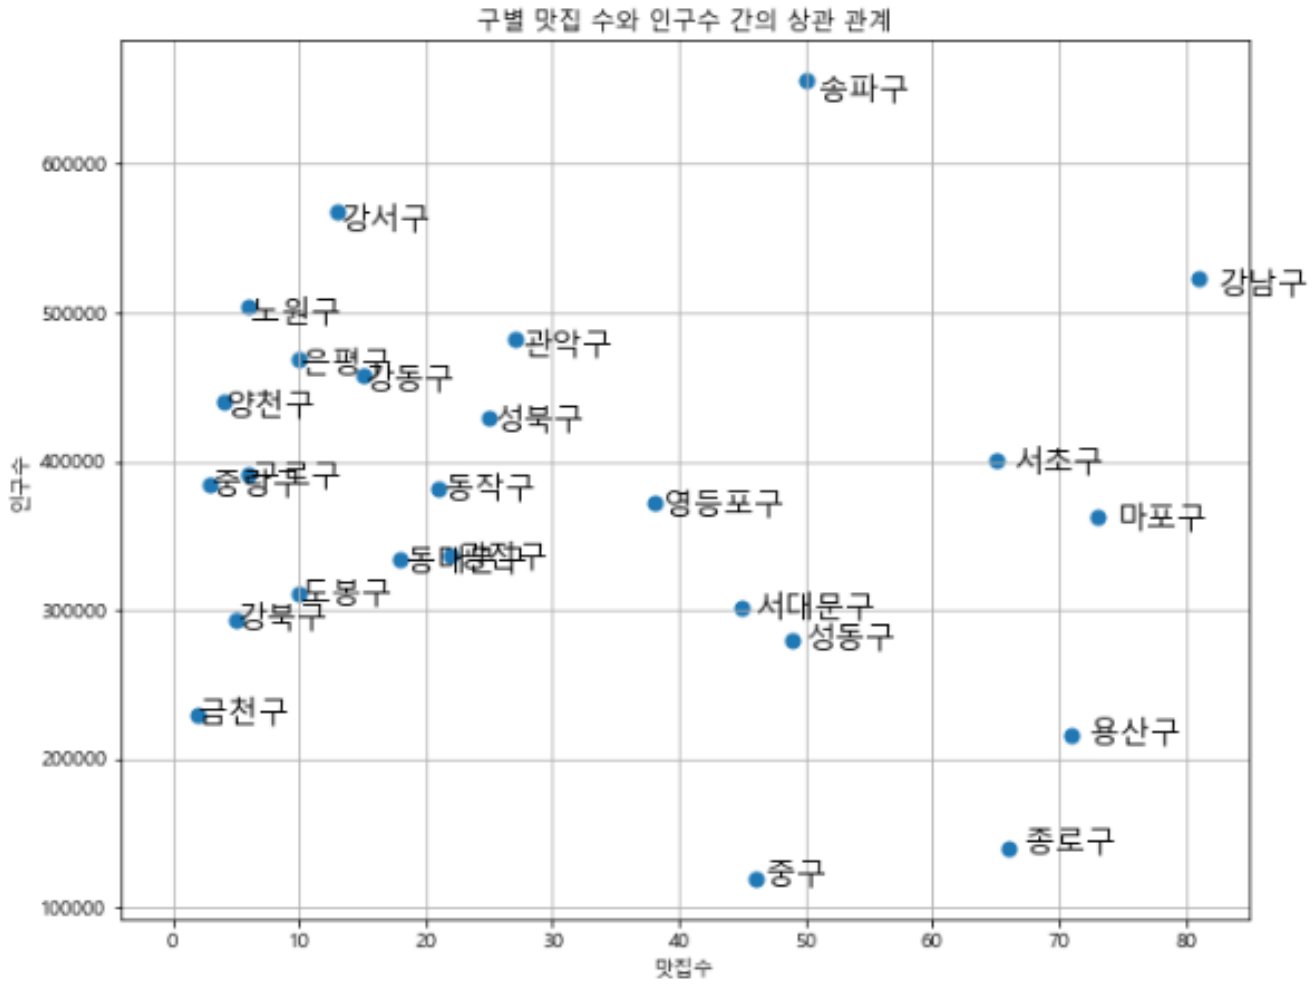

■**산점도 (Scatter)**
-X축:맛집수
-Y축:인구수

■ **결과**
-인구 수가 많다고 해서
꼭 맛집 수가 많은 것은 아니다

#2 인구

<구 별 인구 수와 리뷰 수의 상관관계>

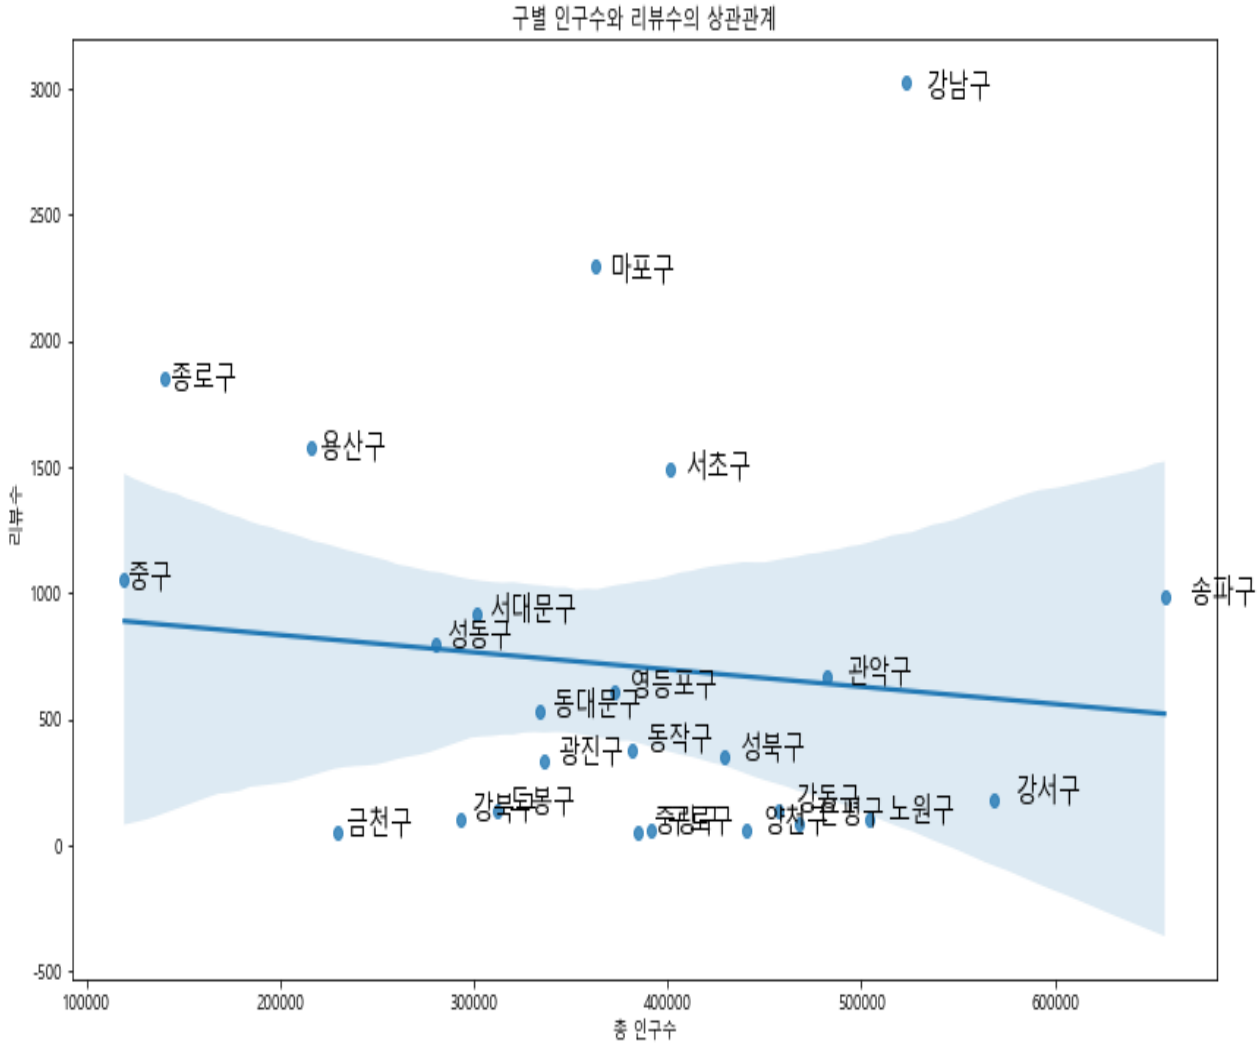

■ **Seaborn 패키지 regplot()**
- 산점도와 선형회귀분석에 의한 회귀선을 함께 나타낸다.
-X축: 총 인구수
-Y축: 리뷰수

■**결과**
-구별 인구수와 리뷰수는 서로 상관관계가 없다

03 데이터 시각화

#3

활동인구 /
사업체 / 인프라

#3 활동인구 / 사업체 / 인프라

< 구 별 맛집 수와 사업체 종사자 수 간의 상관관계 >

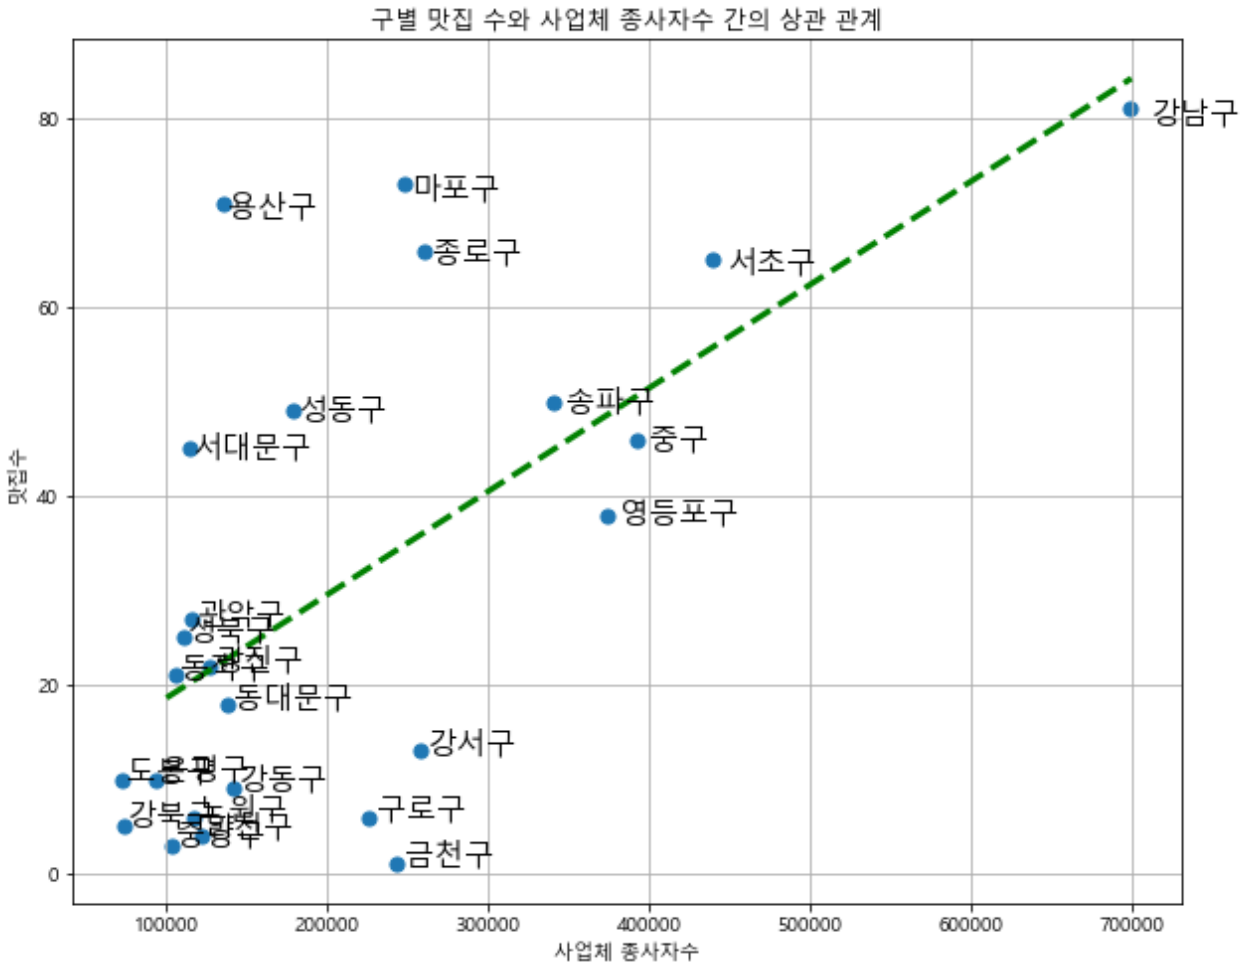


```
print(pearsonr(population['맛집수'], population['사업체종사자수']))
```

```
(0.6251416857877897 0.0008339021081624285)
```

■ **결과**

- 맛집수와 사업체종사자수는 강한 상관관계를 가지고 있다.

->사업체 종사자 수가 적을수록 맛집 수 또한 적다.

#3 활동인구 / 사업체 / 인프라

<구 별 맛집 수와 사업체 수 간의 상관관계>

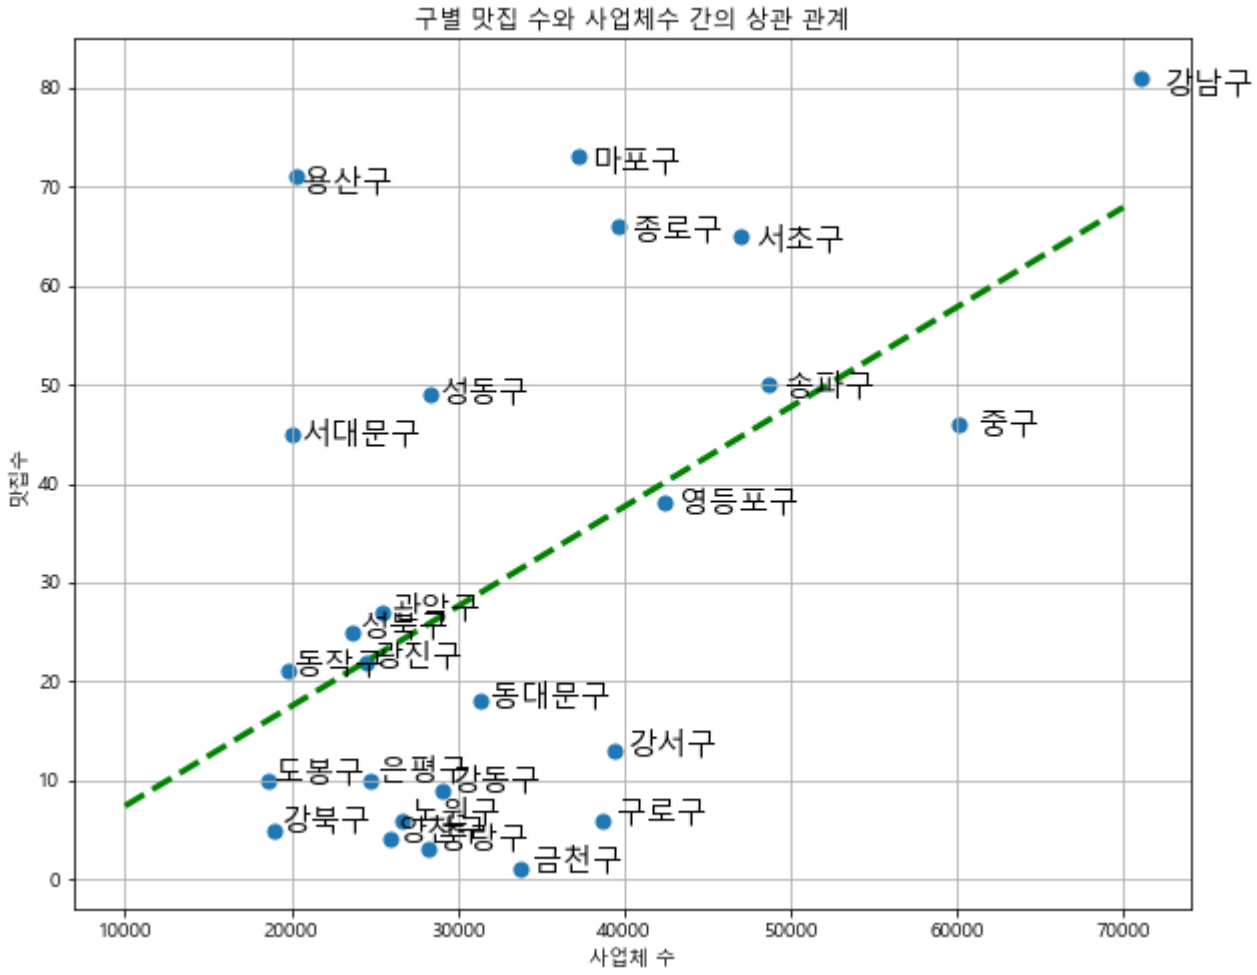


```
print(pearsonr(company['맛집수'], company['사업체수']))
```

```
(0.5190069873532723, 0.007850065973888647)
```

■ **결과**

- 맛집 수와 사업체 수는
  꽤 큰 상관관계를 가지고 있다

-> 보통 사업체 수가 많은 곳에
맛집도 많이 분포한다.

#3 활동인구 / 사업체 / 인프라

< 인접 대학교에서의 거리에 따른 맛집 수 >

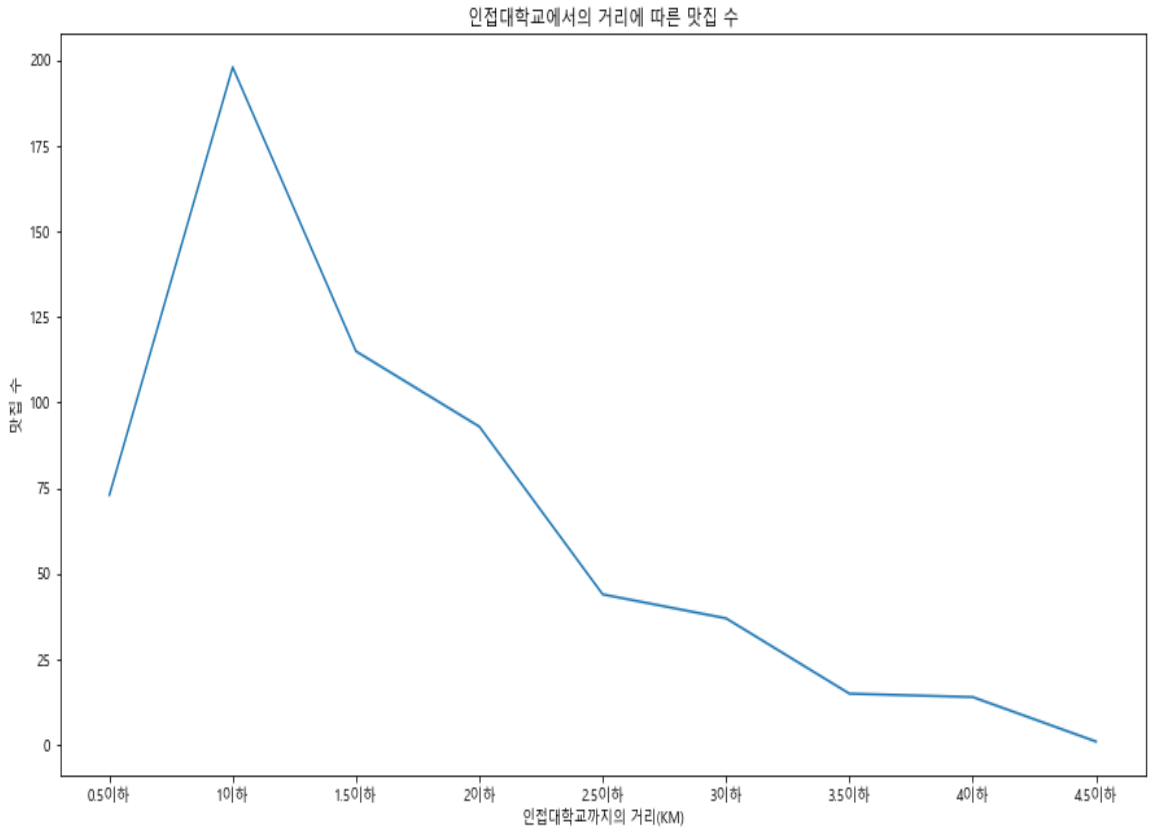

< 인접 지하철역에서의 거리에 따른 맛집 수 >

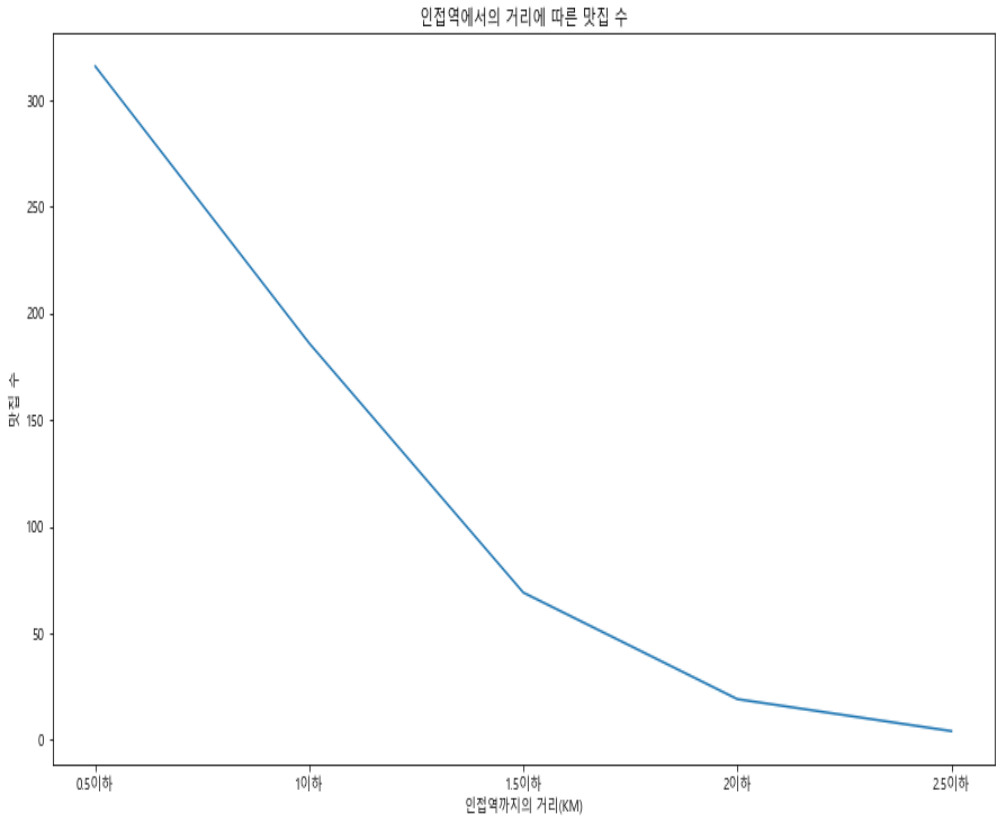

#3 활동인구 / 사업체 / 인프라

Haversine란?
둥근 지구표면에 있는 두 좌표 사이의 거리 구하는 패키지

```
from haversine import haversine
distance = []
for i in range(0, len(res)):
    for j in range(0, len(df_trans)):
        start = (float(df_trans.loc[j, '위도']), float(df_trans.loc[j, '경도']))
        goal = (float(res.loc[i, '위도']), float(res.loc[i, '경도']))
        distance.append(haversine(start, goal))

    res.loc[i, '인접역'] = df_trans.loc[distance.index(min(distance)), '역명']
    res.loc[i, '인접역까지의거리'] = min(distance)
    distance = []
```

맛집 데이터와 공공데이터를 이용한
서울시 자치구별 맛집 상권분석

```
from collections import Counter
a = []
b = []
result = Counter(cat_list)

for key in result:
    a.append(key)
    b.append(result[key])

df_cam = pd.DataFrame((zip(a, b)), columns = ['거리', '수'])
df_cam = df_cam.drop(0, axis = 0)
```

```
ex1 = pd.DataFrame(campus.인접대학교까지의거리.value_counts())
ex1.rename(columns = {'인접대학교까지의거리' : '인접대학수'}, inplace = True)
ex1['인접대학교까지의거리'] = ex1.index

ex1 = ex1.sort_values('인접대학교까지의거리')
ex1.reset_index(inplace = True, drop=True)
tmp = ex1[ex1['인접대학수'] == 7].index
ex1 = ex1.drop(tmp)
```

```
dis = ex1['인접대학교까지의거리'].to_list()
data = dis
bins = [0, 0.5, 1, 1.5, 2, 2.5, 3, 3.5, 4, 4.5]
labels = ['0.5이하', '1이하', '1.5이하', '2이하', '2.5이하', '3이하', '3.5이하', '4이하', '4.5이하']
cats = pd.cut(data, bins, labels = labels)
cat_list = list(cats)
```

■지도 상 좌표간의 거리 구하는 코드

- Geocode로 모든 주소 위경도 좌표로 반환

-Haversine메소드로 맛집과의 거리를 구해 리스트에 저장

-리스트 내의 가장 작은 값 구한 후

해당 Index(대학교 or 지하철역 이름)을 저장

- 거리에 따른 맛집의 수 구하기 :Cut() 사용

- 일정 거리별 맛집의 수 구하기:Counter() 사용

#3 활동인구 / 사업체 / 인프라

< 인접 대학교에서의 거리에 따른 맛집 수 >

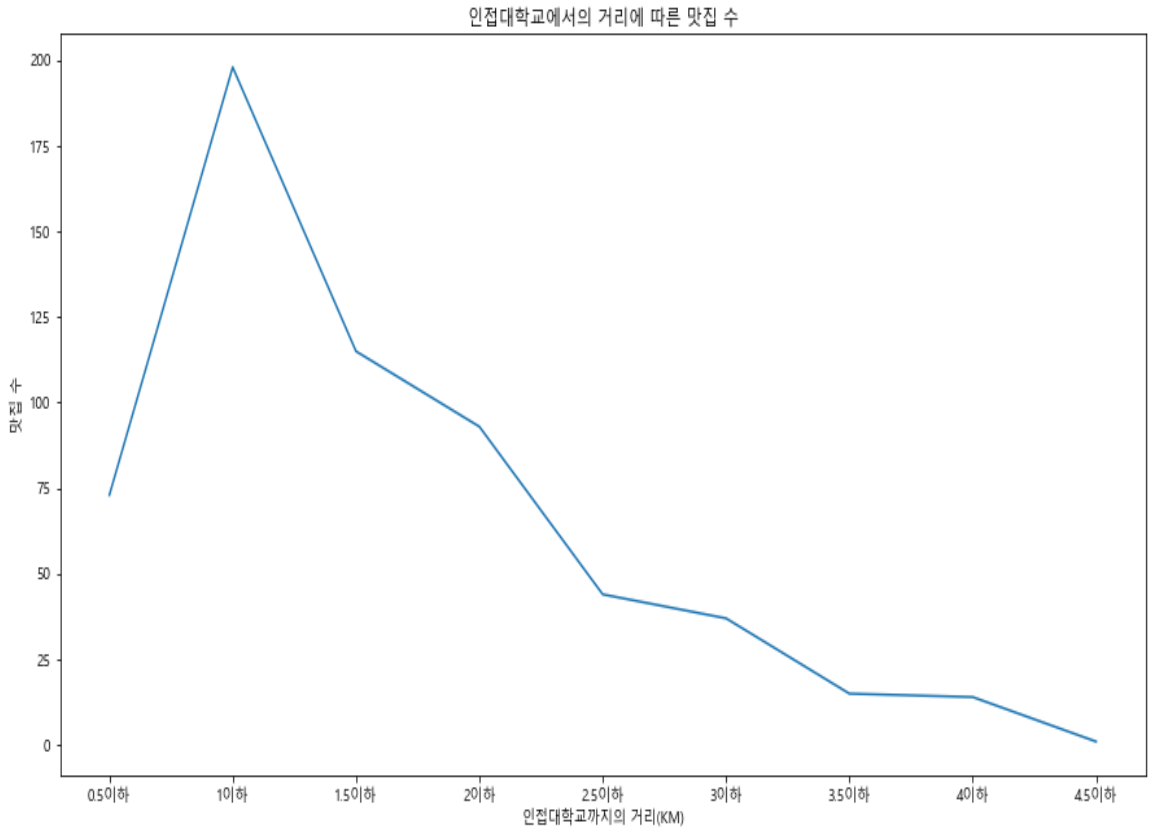

< 인접 지하철역에서의 거리에 따른 맛집 수 >

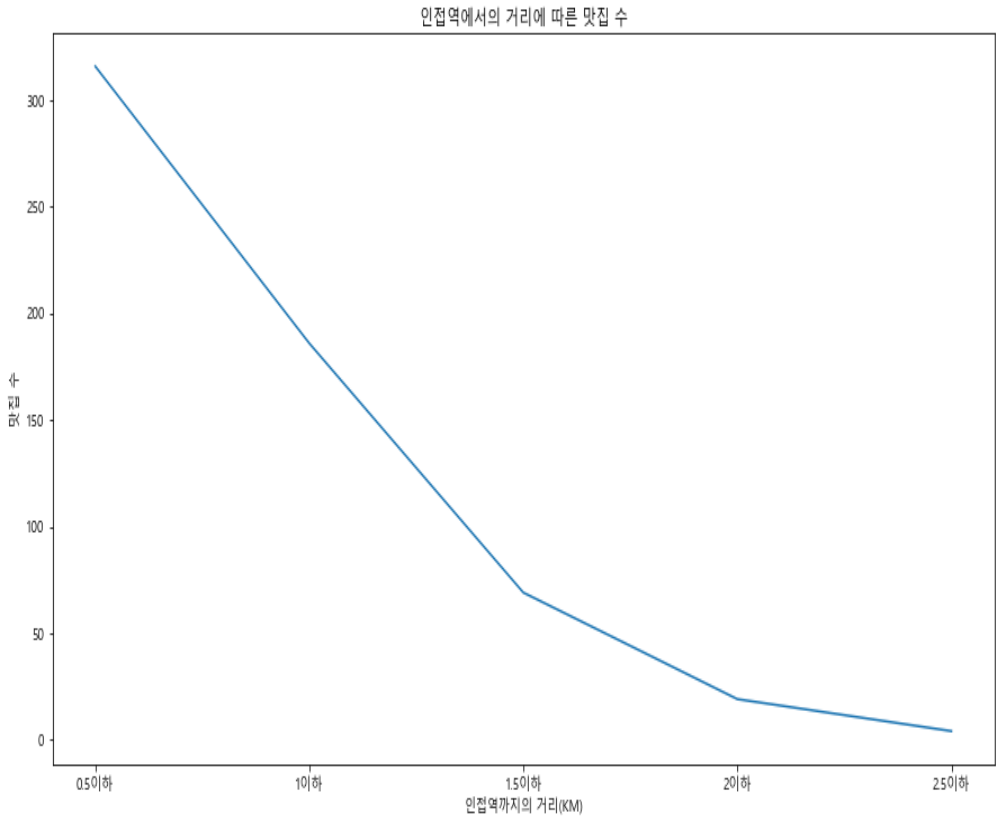

03 데이터 시각화

#4

소득(GDP)

#4 소득(GDP)

< 구 별 GDP↔ 맛집 가격점수 >

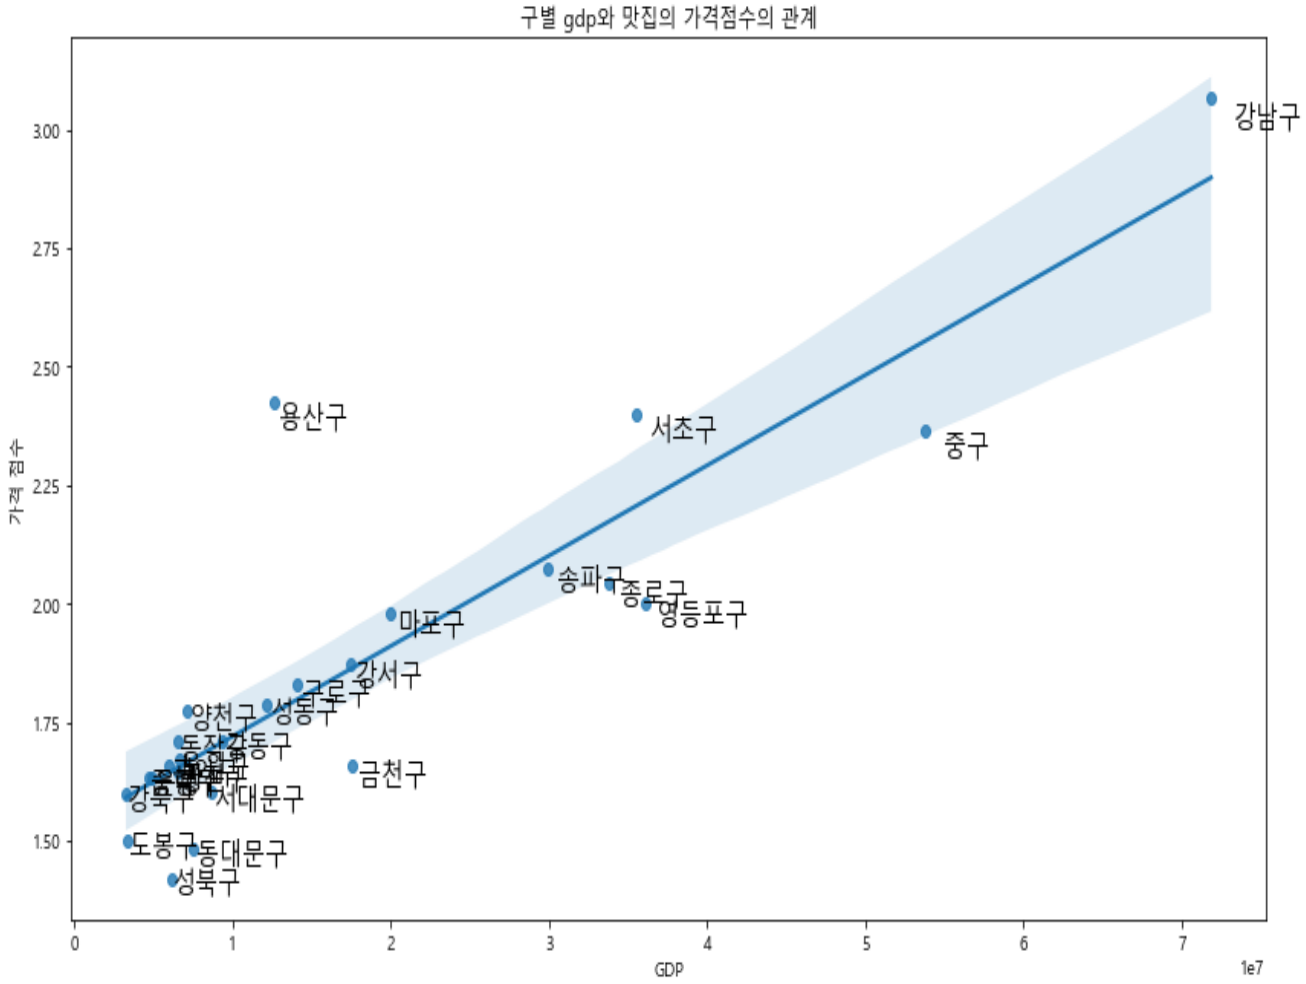


```
print(pearsonr(df['GDP'], df['가격 점수']))
```

```
(0.8789649046326994, 7.429293031312685e-09)
```

■ **가격점수**

- ({가격대 상대점수(각 1,2,3,4,5점)} * {자치구의 가격대별 맛집 수})/자치구별 맛집 수

■**결과**

- GDP가 낮은 쪽이 가격점수도 낮은 걸로 나타나므로 둘은 강한 상관관계를 가진다.

  -> 총생산이 높을수록 맛집 평균 가격대가 올라간다.

#4 소득(GDP)

< 구 별 맛집 수↔소득세 >

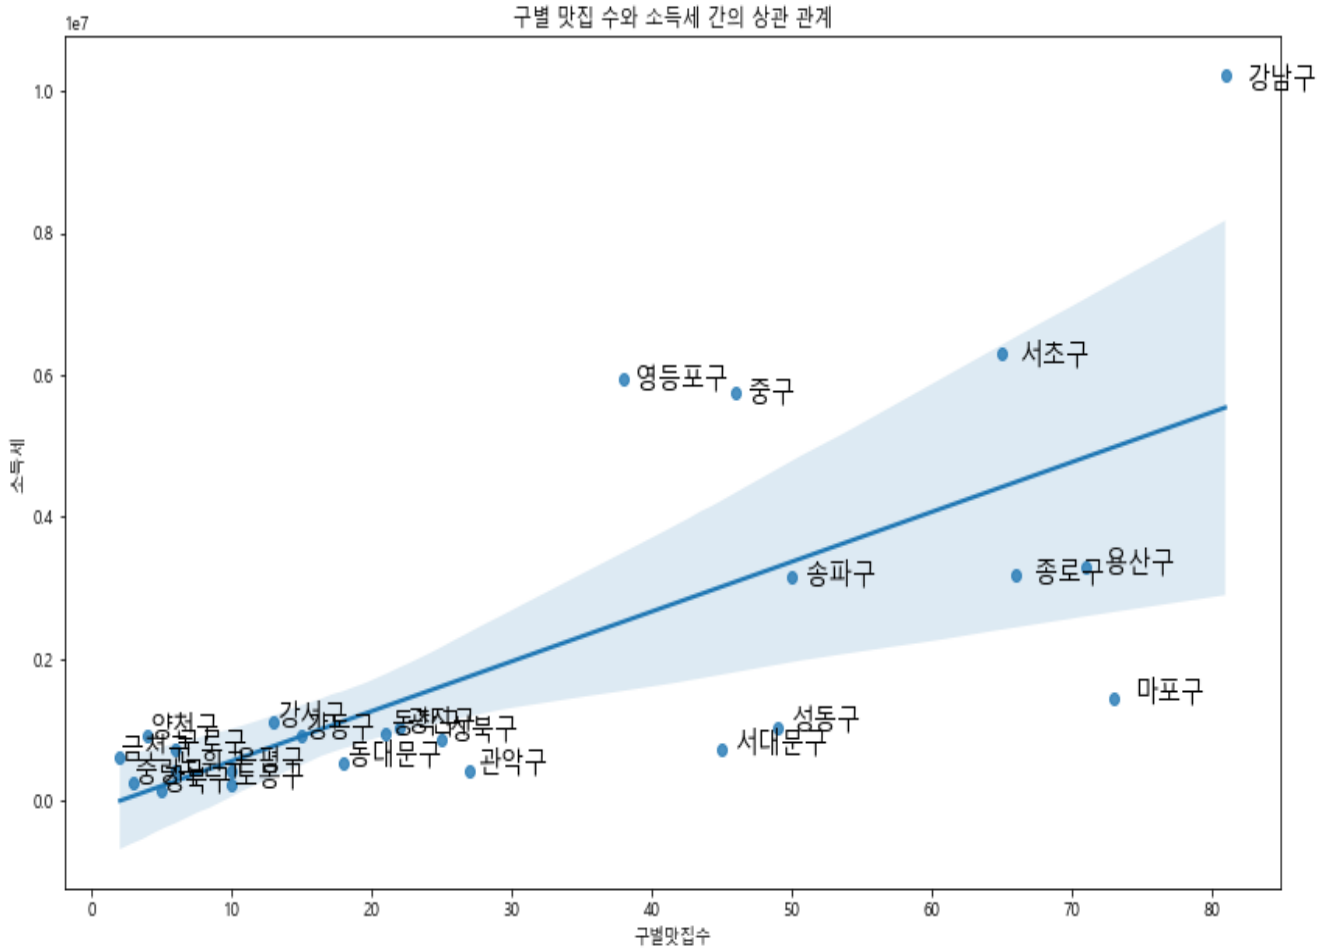


```
print(pearsonr(df_tax['구별맛집수'], df_tax['소득세']))
```

```
(0.7081861588087626, 7.467343220764394e-05)
```

■결과

- 소득세를 많이 내는 구일수록 맛집의 수가 많다

#4 소득(GDP)

< 구 별 소득세↔가격점수 >

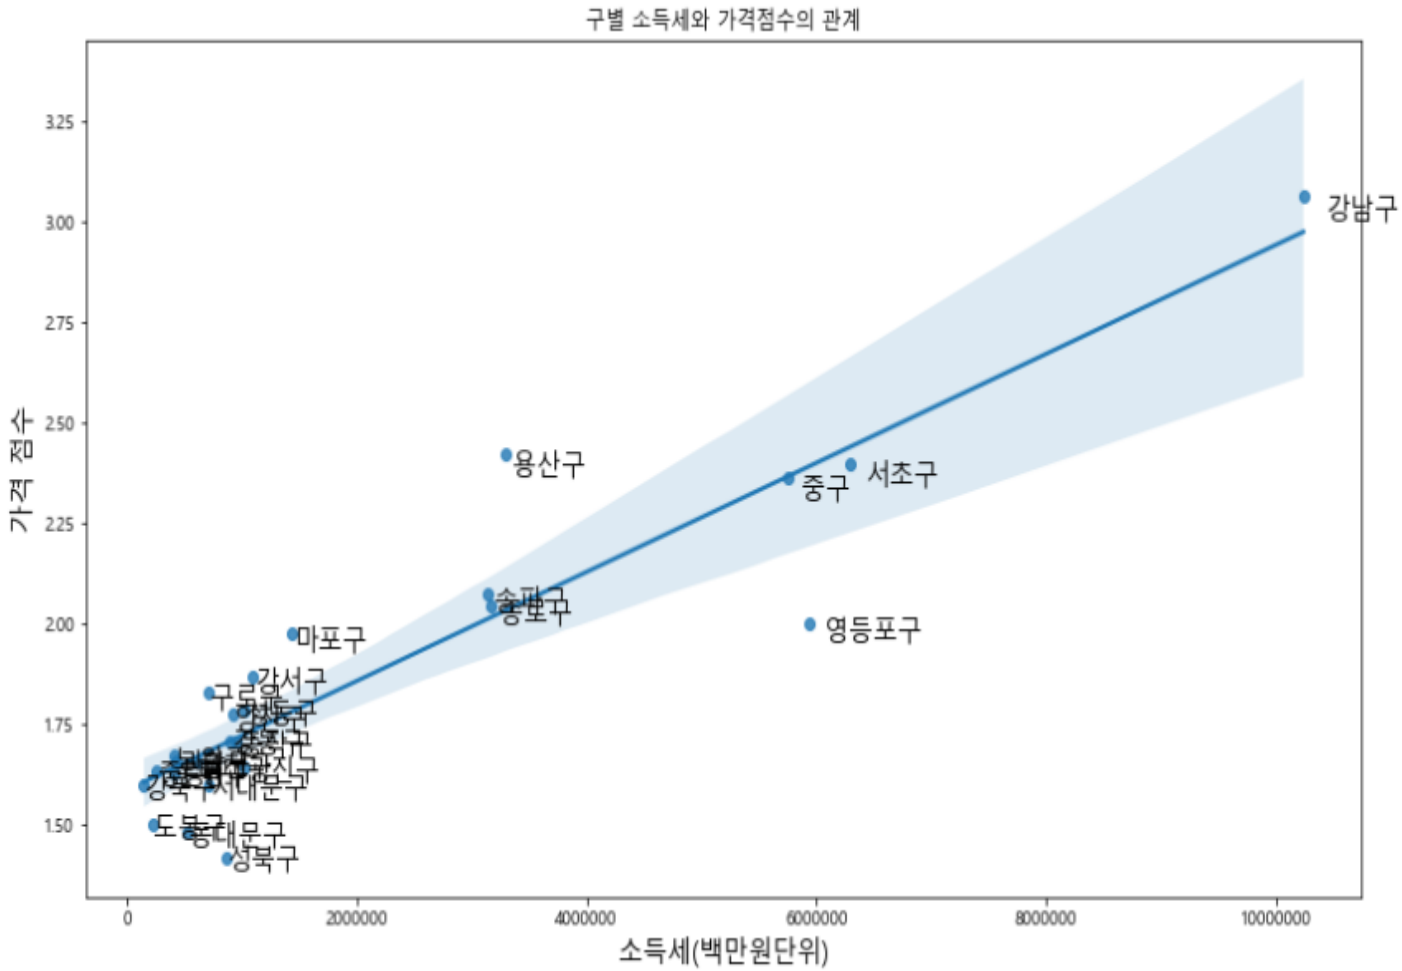


```
print(pearsonr(tax['소득세'], tax['가격 점수']))
(0.9144750319019931, 1.6386374859486384e-10)
```

■ **결과**

- 소득세가 가격 점수에 비례한다.
  -> 소득세를 많이 내는 구일수록 가격 점수가 높다.

04 결과 후기 및 느낀점

04 결과 후기 및 느낀점

아쉬웠던 점

- 웹크롤링: 웹사이트(망고플레이트)의 속도 문제로 인한 데이터 수집의 한계

- 예상했던 결과와 다른 데이터 분석,시각화 결과물
  -> 평균적인 생각과 실제의 차이 가능성 확인

기대효과

- 다양한 니즈에 따른 정보 확인 가능

  ■식당 창업 시 고려할 정보

  ■가격대 데이터를 통해 음식의 적정가 책정에 도움

  ■가고싶은 맛집의 위치 및 정보

- 추후 해당 데이터 분석 결과를 바탕으로 경쟁력 있는 음식 종류,가격대 등을 이용하여 맛집 추천 시스템 개발로의 발전 가능성

감사합니다 ☺